LogoType™

TodayNews
중간 결과 보고

Meeting Using DeepLearning

201601364 박주영(T)　　201503665 홍승환　201600599 김아연
201701138 김혜원　　201700124 이산가 비두샤

목차

머신러닝을 이용한 뉴스 제공 서비스

즉, **뉴스를 봐야겠다고 생각은 하나, 뉴스를 보지 않는 사람들**에게 오늘 하루의 뉴스를 요약하여 제공하는 어플입니다.

Today News

News summary using machine learning

1. TN Services 소개

Today news어플리케이션을 통해 제공받을 수 있는 서비스입니다.

1. 뉴스 요약본 제공

실시간으로 뉴스 요약본을 제공합니다.

2. 주제별 뉴스

뉴스를 군집화하여 주제별로 묶어서 보여줍니다.

3. 개인화 추천 기능

사용자별 맞춤 뉴스를 추천하여 보여줍니다.

4. 북마크 기능

사용자가 원하는 내용을 스크랩하여 후에 다시 볼 수 있습니다.

5. 뉴스 브리핑 기능

군집화된 뉴스의 요약본을 브리핑 해주는 기능이다.

6. 잠금화면

스마트폰의 잠금화면에서 실시간 뉴스를 제공받을 수 있습니다.

2. 시스템 구성도 및 흐름도

TN 시스템 구성도

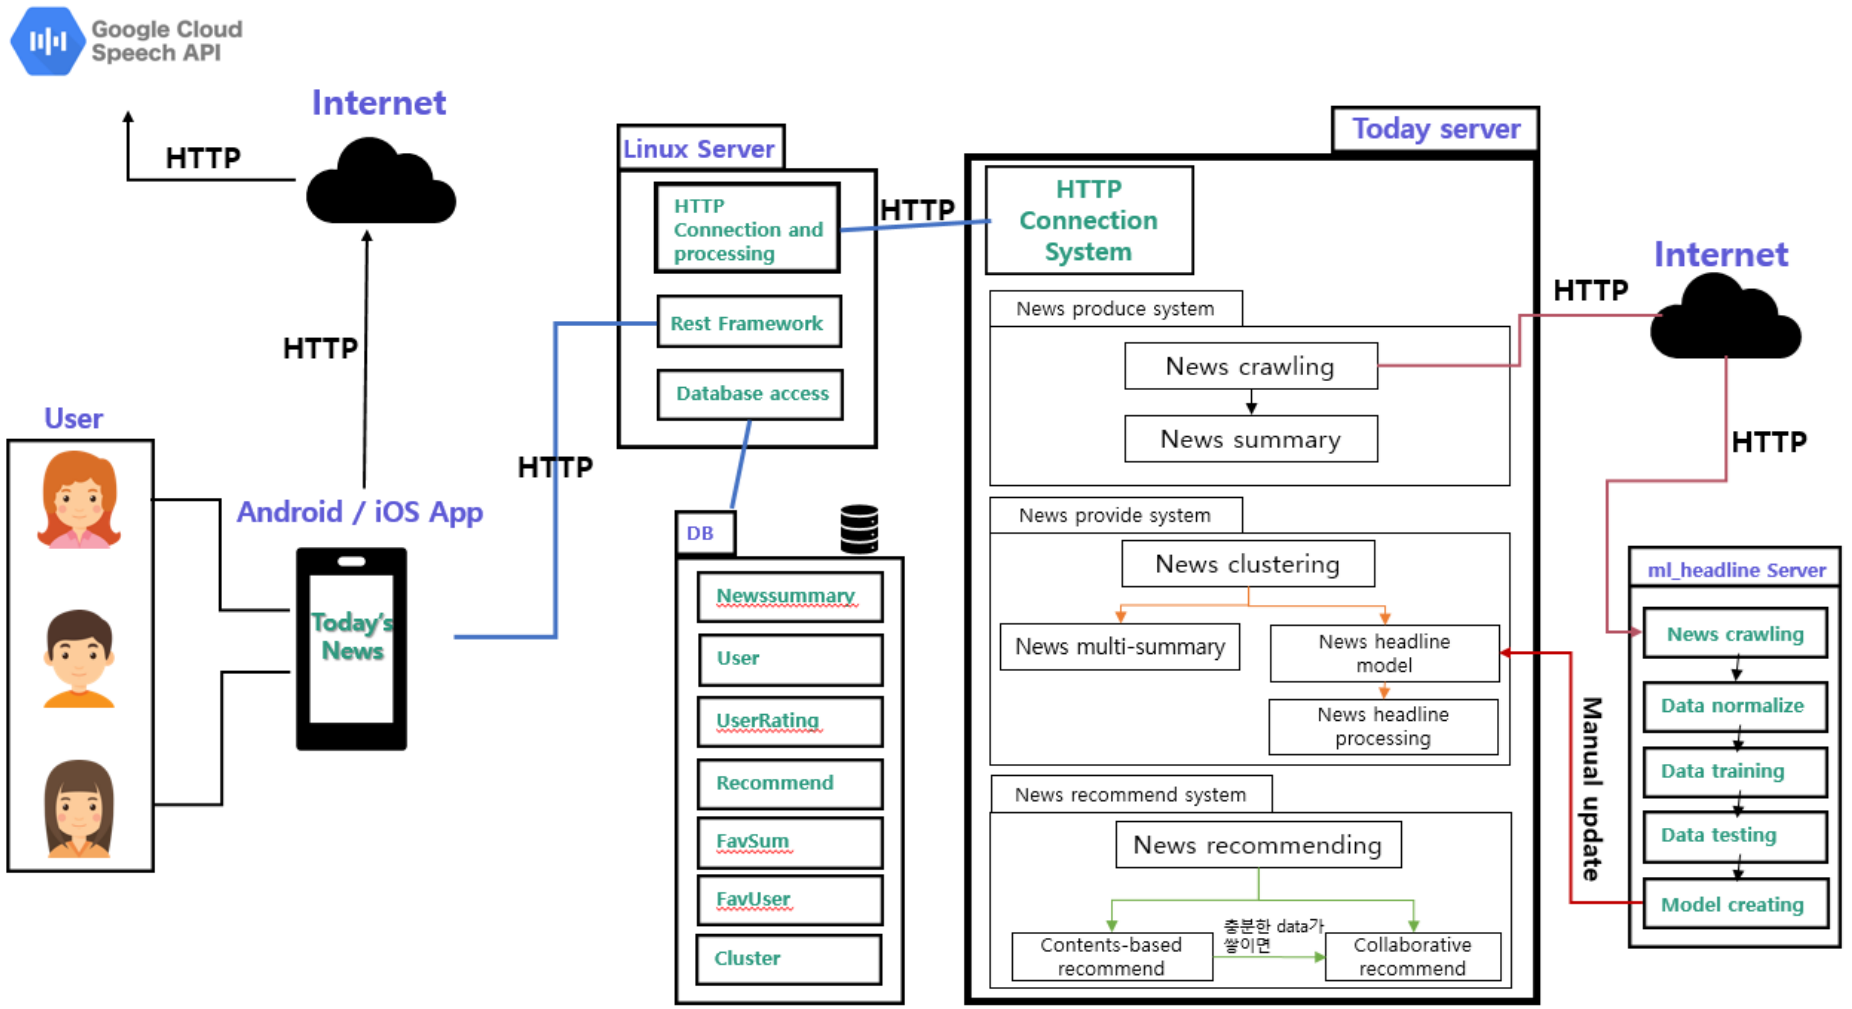

2. 시스템 구성도 및 흐름도

TN 시스템 흐름도

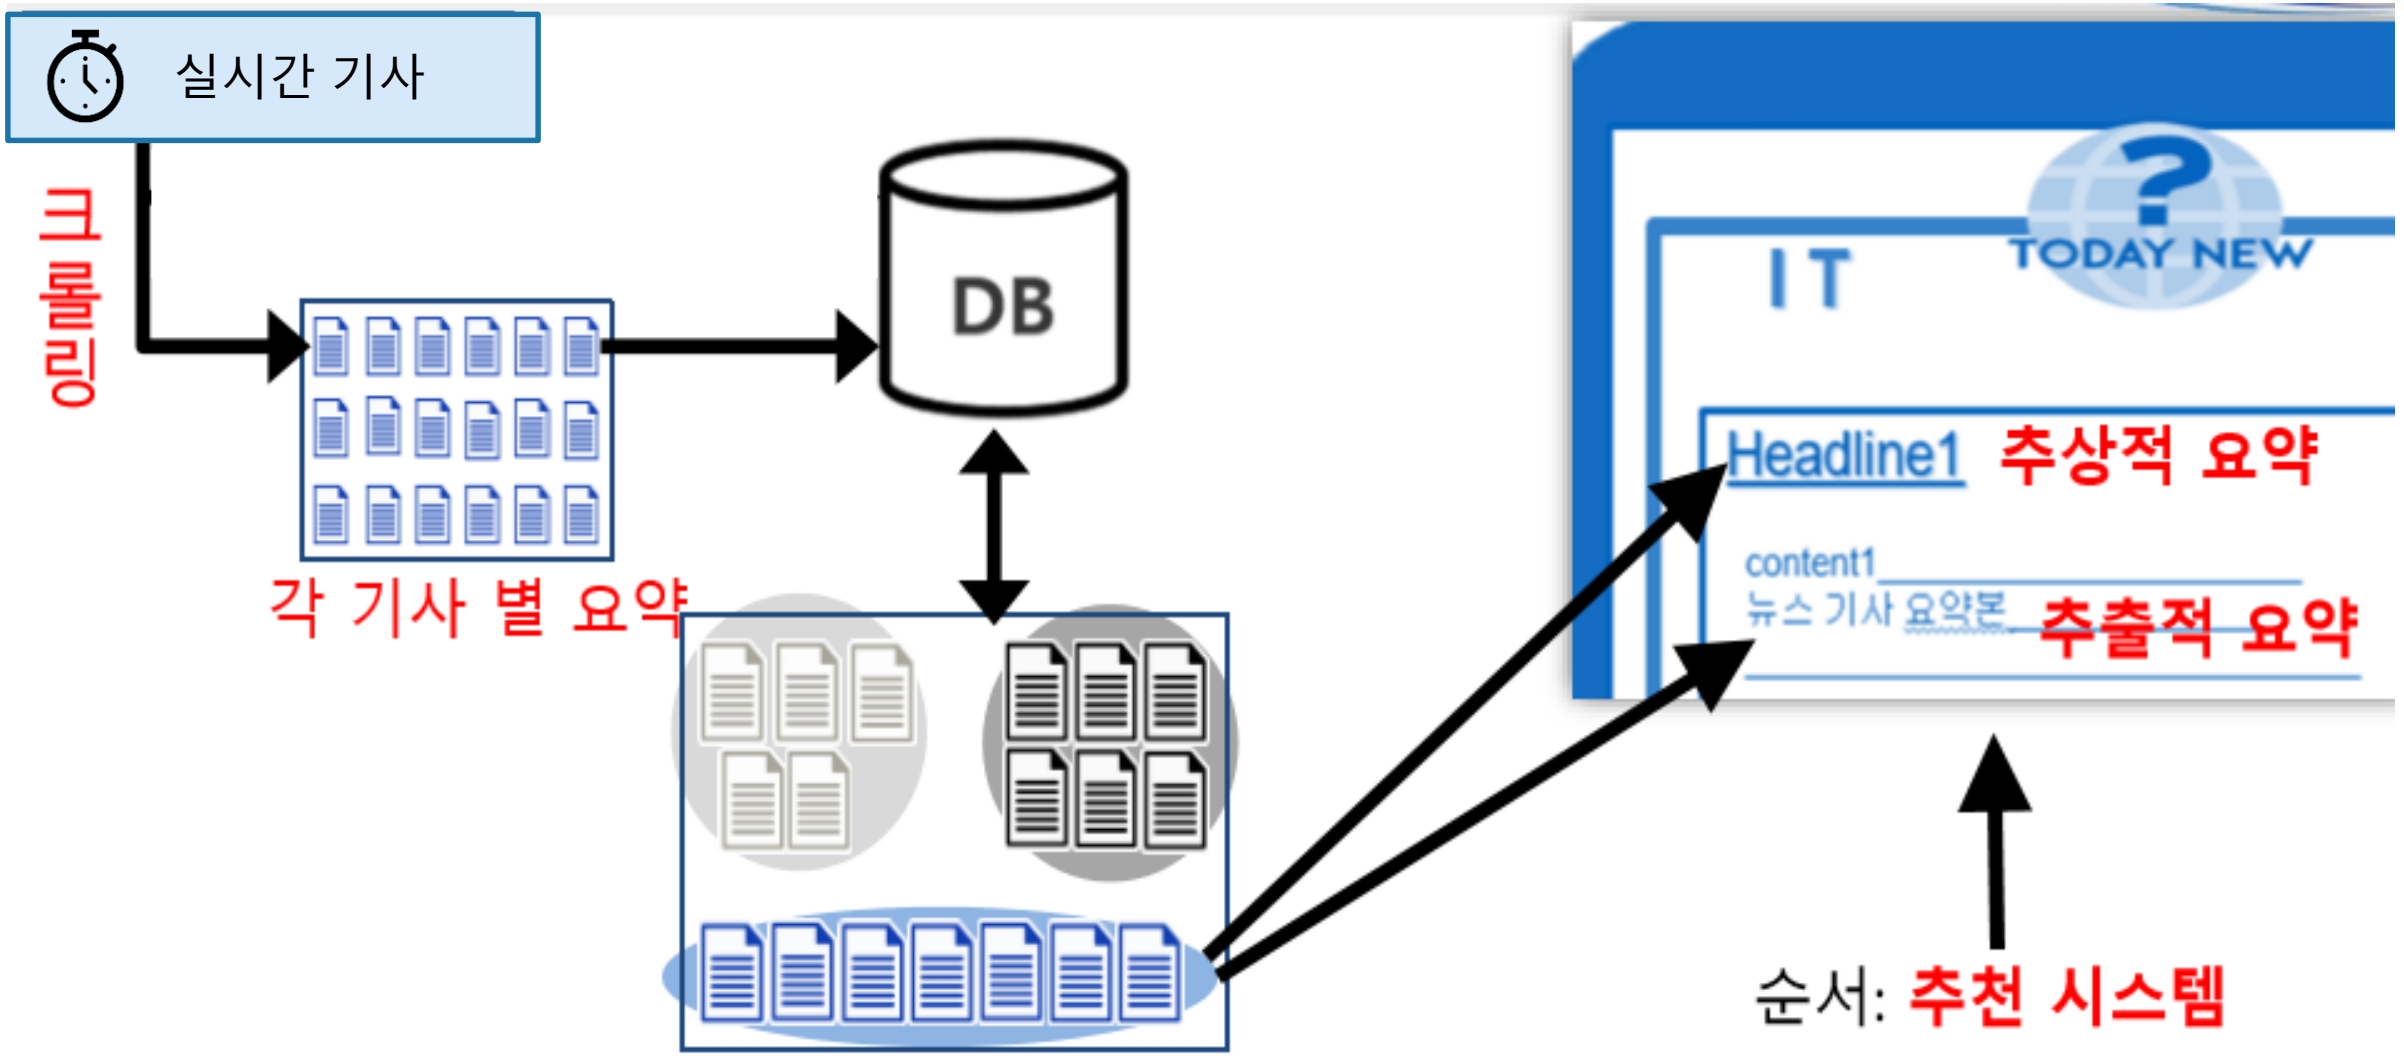

3. 시스템 별 구현 현황

주요 기능 목록

유형	주요 기능	설명	진척도(%)
앱	로그인 및 회원가입	사용자가 이메일인증을 통해 회원가입을 하고 로그인 기능을 통해 서비스를 이용할 수 있다.	100%
	화면 제공	뉴스를 볼 수 있는 메인 화면과 카테고리 화면, 회원 정보와 스크랩 기능이 있는 회원 정보 화면을 제공한다.	90%
	TTS기능	군집화된 뉴스의 요약본을 브리핑 해주는 기능이다.	100%
	스크랩 기능	사용자가 원하는 뉴스를 스크랩하여 뉴스 정보를 DB에 저장하여 후에 다시 볼 수 있도록 한다.	0%
뉴스 생성 시스템	뉴스 크롤링	실시간으로 정치, 경제, 사회, IT 뉴스를 크롤링 한다.	100%
	뉴스 요약본 생성	Lexrank를 이용하여 뉴스를 3줄로 요약한 후 db에 저장한다.	100%
뉴스 제공 시스템	뉴스 클러스터링	K-means를 이용하여 주제별로 뉴스를 클러스터링한다.	70%
	헤드라인 생성	딥 러닝을 이용하여 생성된 모델을 통해 각 뉴스 군집의 헤드라인을 추상적 요약 기법으로 생성한다.	70%
	다중 문서 요약	군집화된 뉴스들을 모아 다시 한번 요약하여 각 군집의 대표 요약본으로 제공	80%
뉴스 추천 시스템	개인화 추천 뉴스 제공	콘텐츠기반, 협업필터링을 이용하여 개인별 맞춤 뉴스를 추천한다.	90%

3-1. APP개발 세부 진행 사항

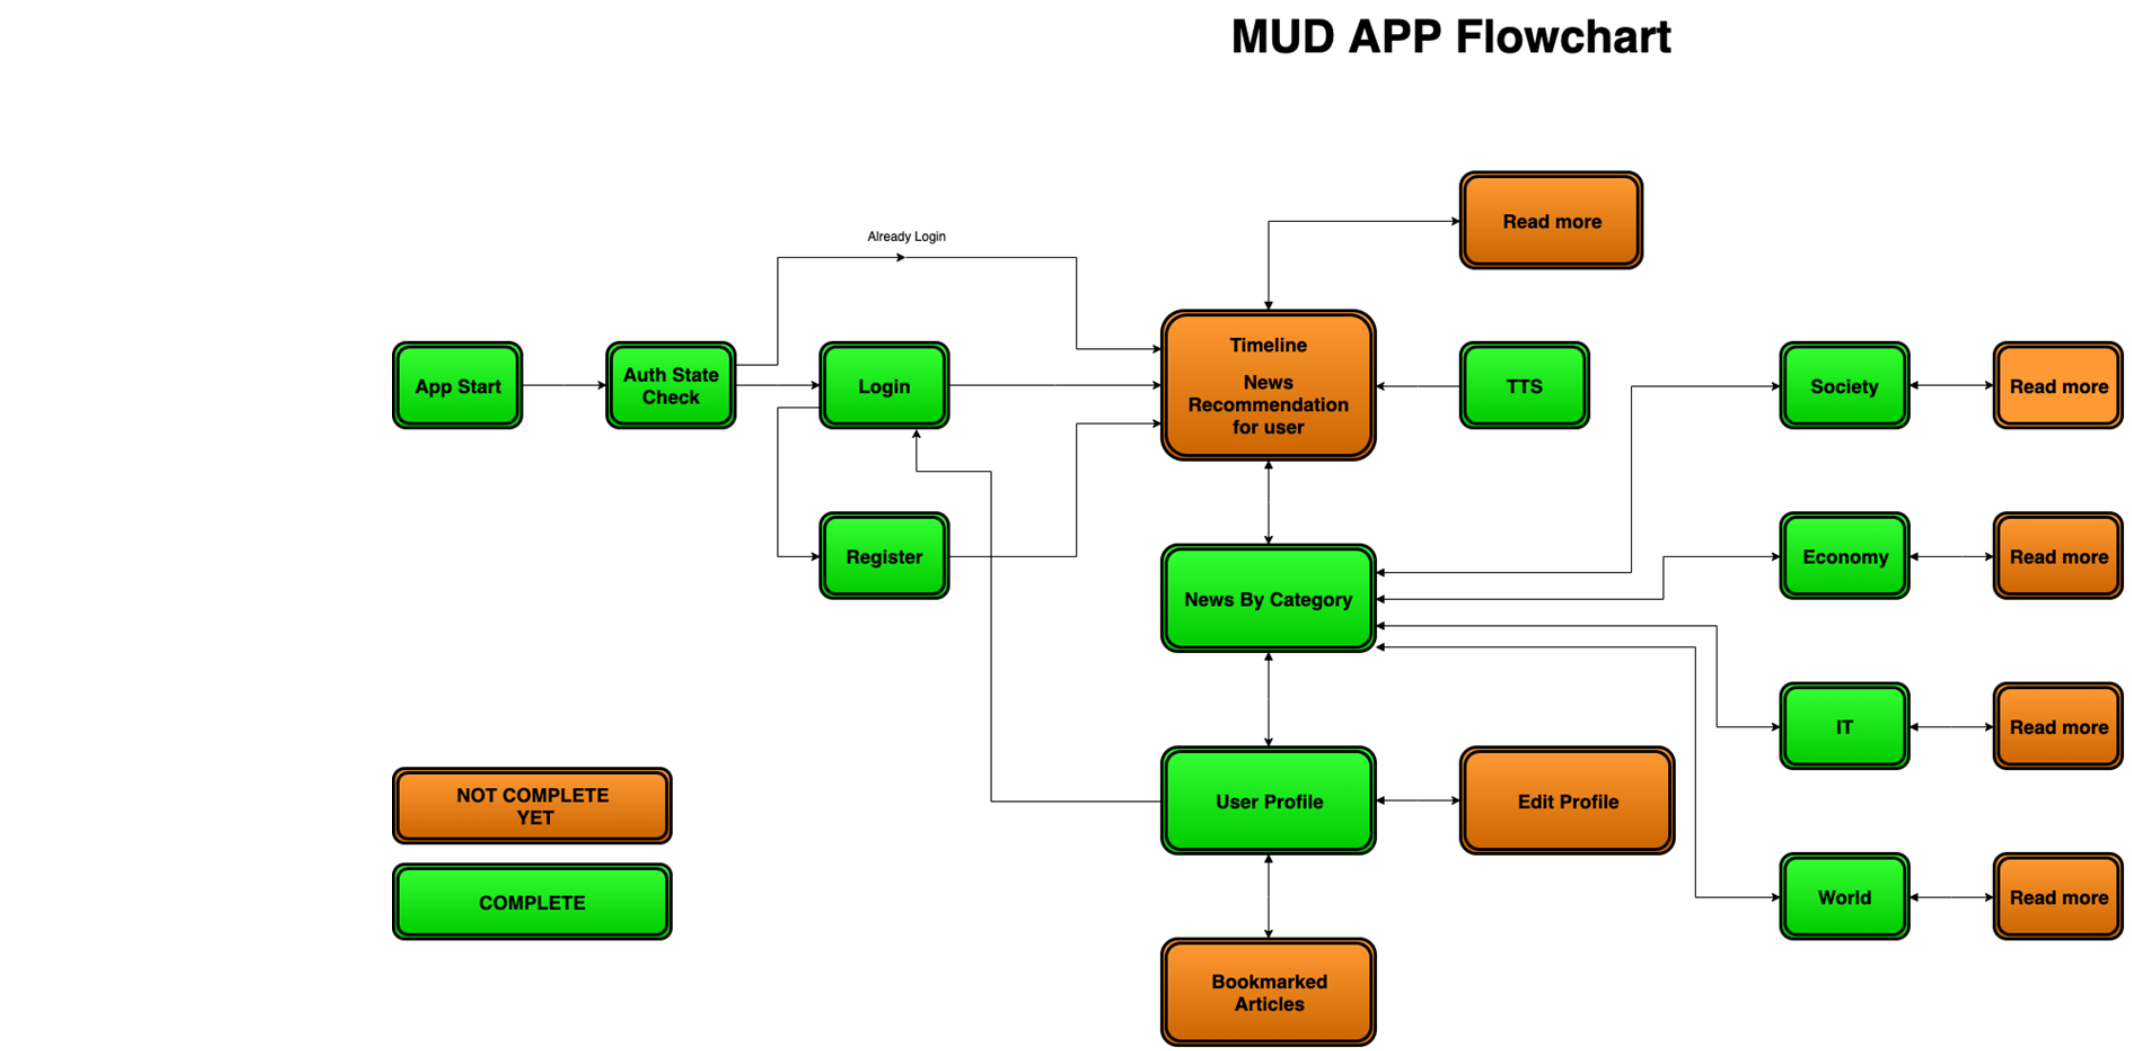

Cloud Architecture

Architecture: Django > Rest API > Content Hosting

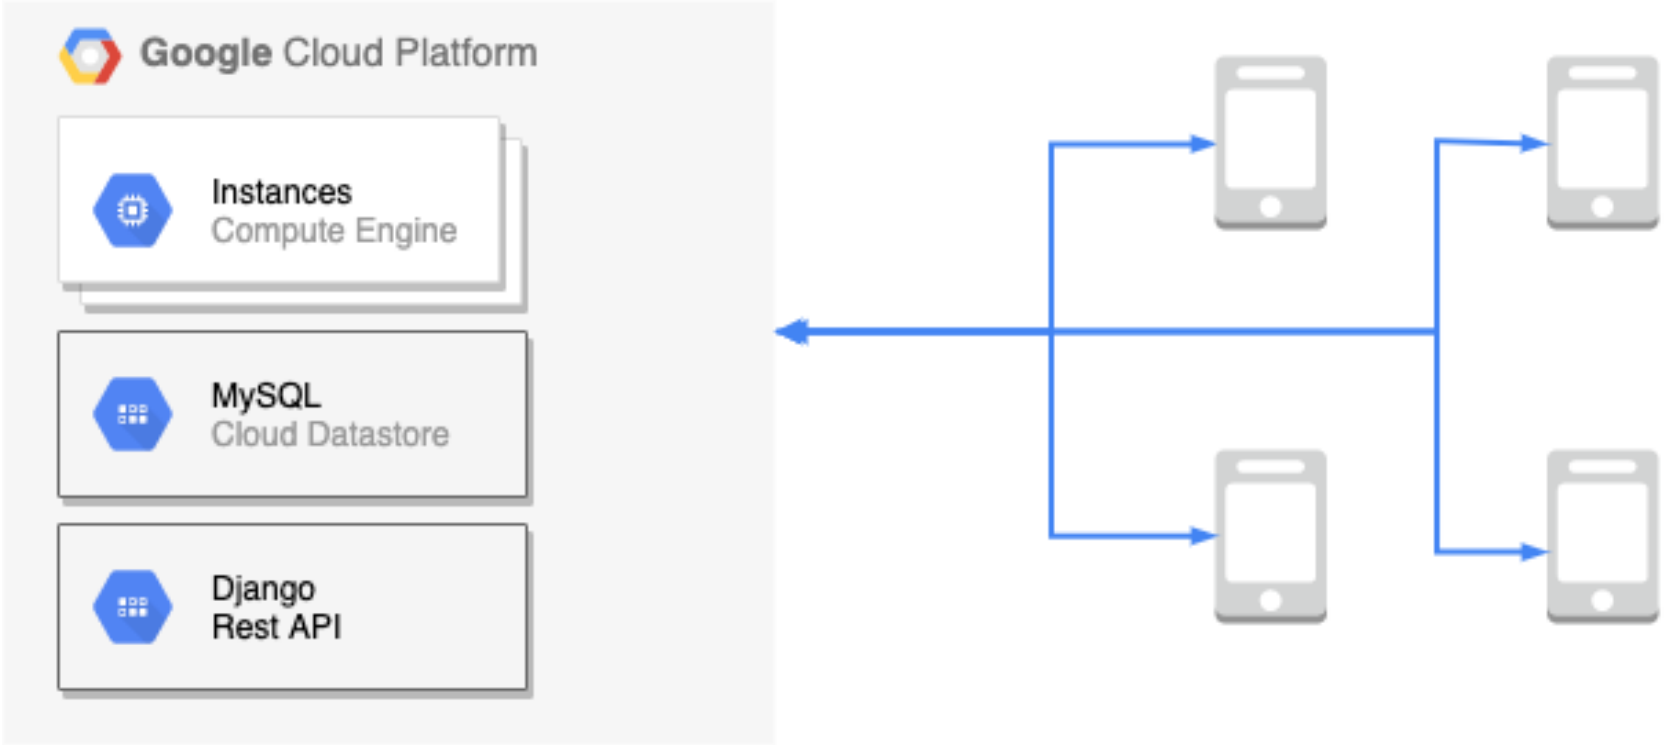

데이터 베이스 설계

MySQL Database

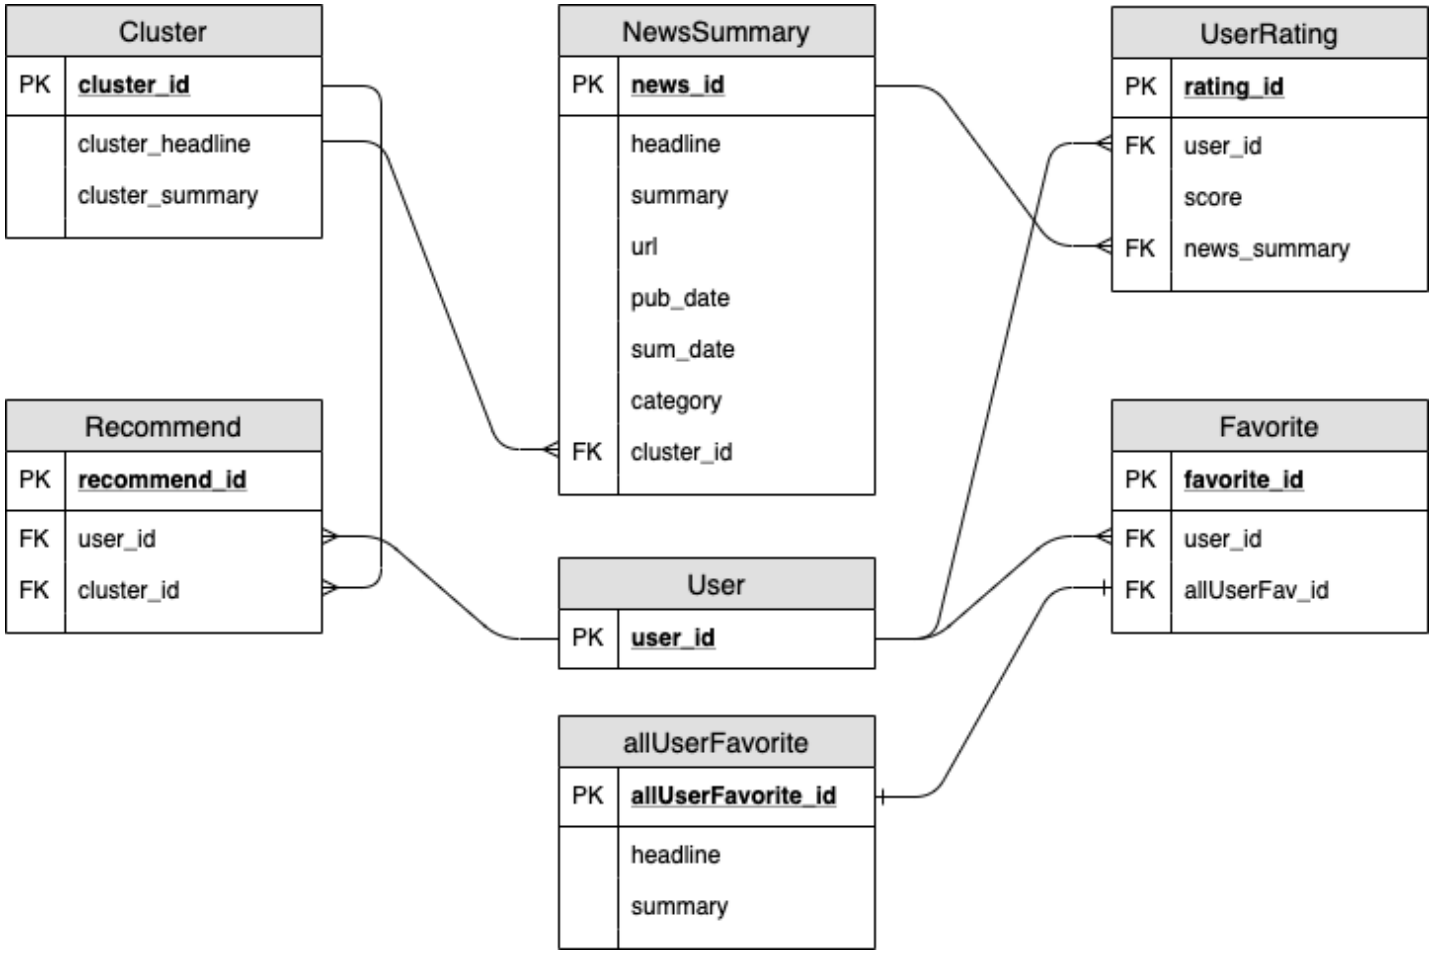

3-2. 뉴스 생성 시스템 구현 현황

Crawling &summary

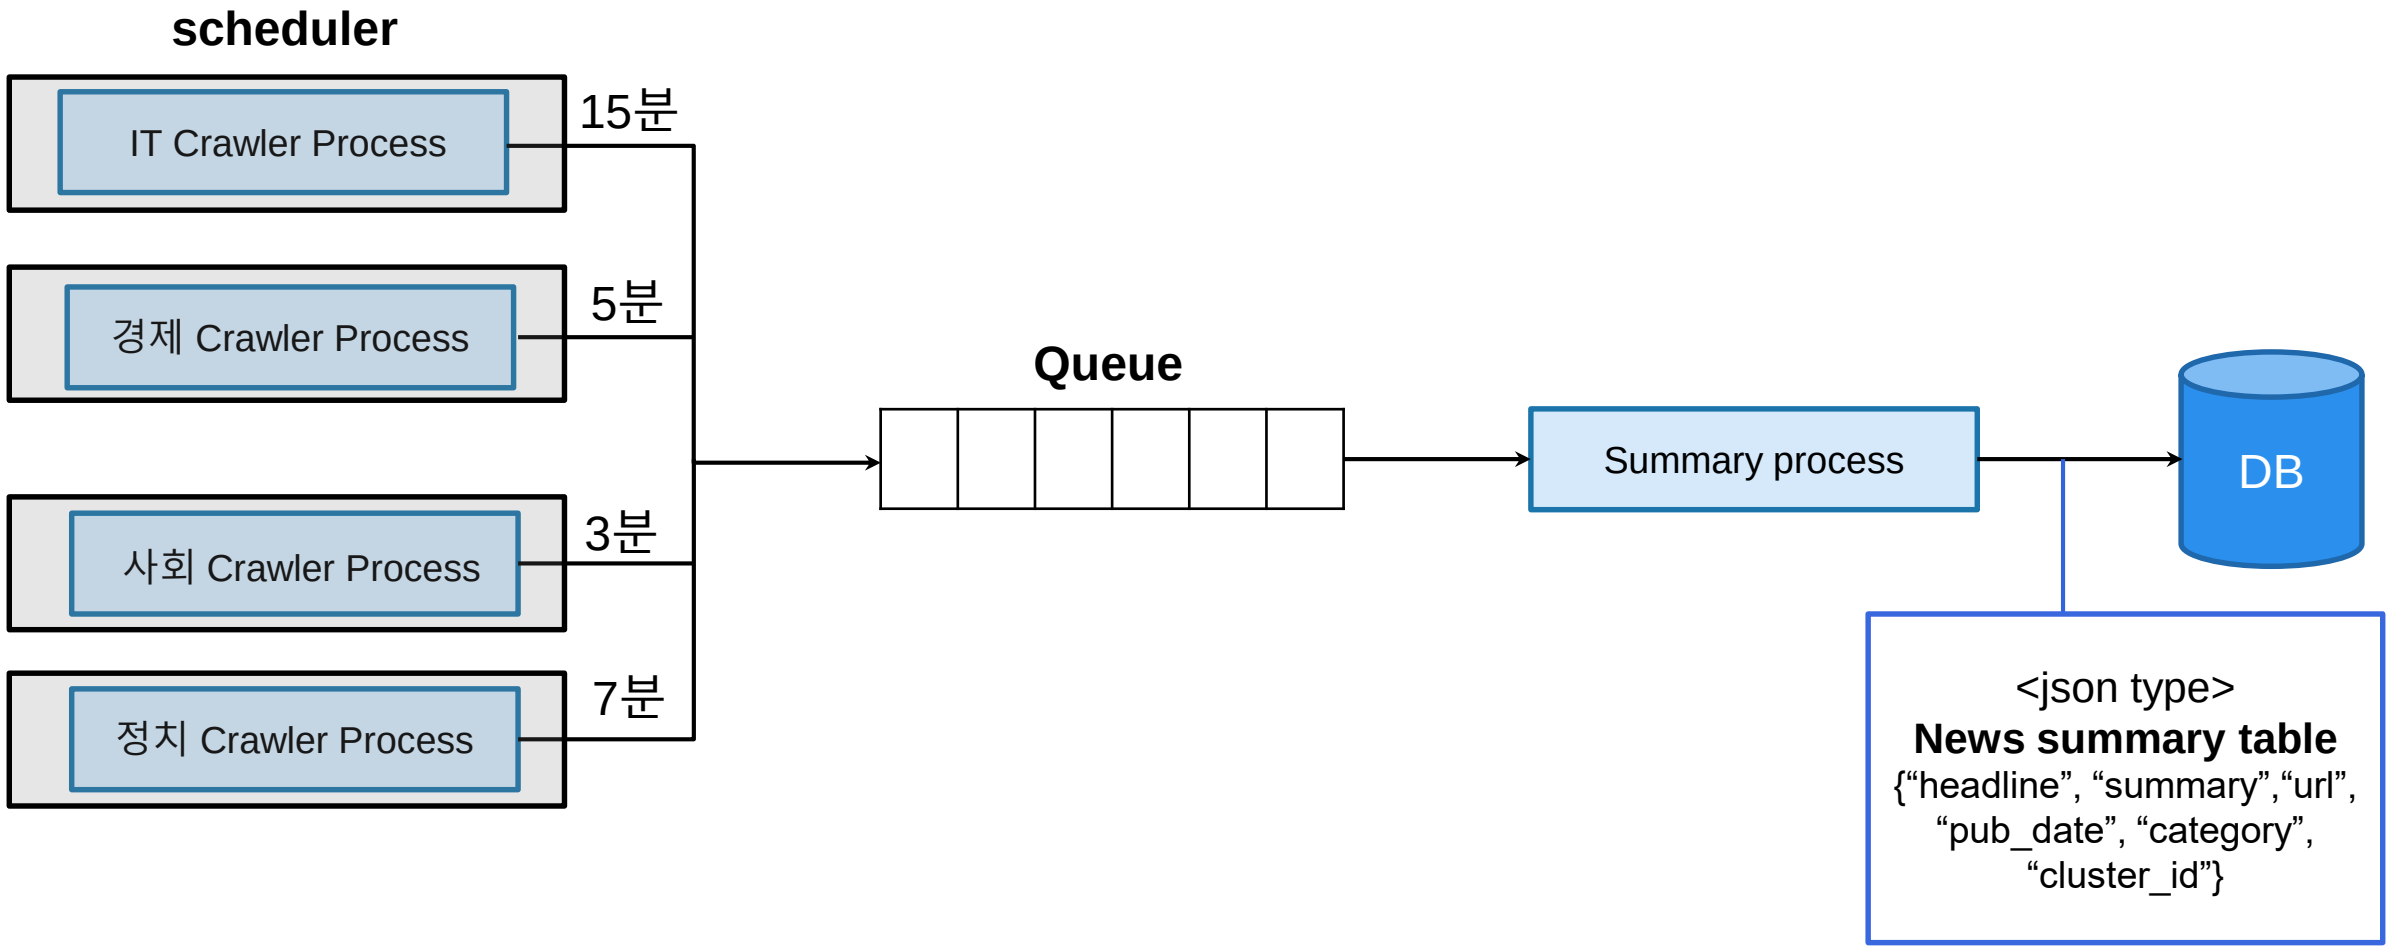

3-2. 뉴스 생성 시스템 구현 현황

Crawling &summary 결과

1. 결과를 리스트로 출력

- 크롤링 후 뉴스 본문을 요약한 데이터를 리스트로 저장한다.
- Data = [오늘날짜,카테고리,언론사,제목,요약본문,ur,뉴스생성시간]으로 저장한다.
- 결과 예시: [‘20191119‘,’society’,’연합뉴스’,’프랑스 남부서 현수교 붕괴,,,’,’스용차 타고 있던 15세 청소년 숨진 채 발견. 트럭 운전사도….’,’2019.11.19.12.50’]

3-2. 뉴스 생성 시스템 구현 현황

Crawling &summary 결과

2. DB에 json형식으로 결과를 저장


```
{
    "news_id": "5165a1e2-2c04-48f6-ad67-faf4be51a426",
    "headline": "“선명도 미달” vs “번인 현상” LG·삼성 8K TV 주도권 전쟁",
    "summary": "LG전자는 삼성전자의 양자점발광다이오드 QLED TV를 화질 선명도가 떨어지는 유사 유기발광다이오드 OLED TV라 공격하고 삼성전자는 LG전자 OLED TV의 번인 Burn in·열화 현
    "url": "https://news.naver.com/main/read.nhn?mode=LSD&mid=sec&sid1=101&oid=353&aid=0000035532",
    "pub_date": "2019-11-16T12:35:00+09:00",
    "sum_date": "2019-11-16T02:46:18.239363+09:00",
    "category": "경제",
    "cluster_id": "01873b9c-244d-4744-afb9-3a2dc34dbfd1"
},
{
```


- REST API를 이용해 News summary table의 url과 통신을 한다.
- Date = {“headline” : date[3], “summary” : date[4], “url”: date[5], “pub_date”:date[6], “category”:date[1], “cluster_id”:”…”} 의 json 형식으로 DB에 저장하며 앞서 생성된 data 리스트에서 알맞은 값을 value로 지정하여 준다.
- 요약된 뉴스는 실시간은로 앱에서 확인 가능하다.

3-3. 뉴스 제공 시스템 구현 현황

- K_means 이용한 Clustering

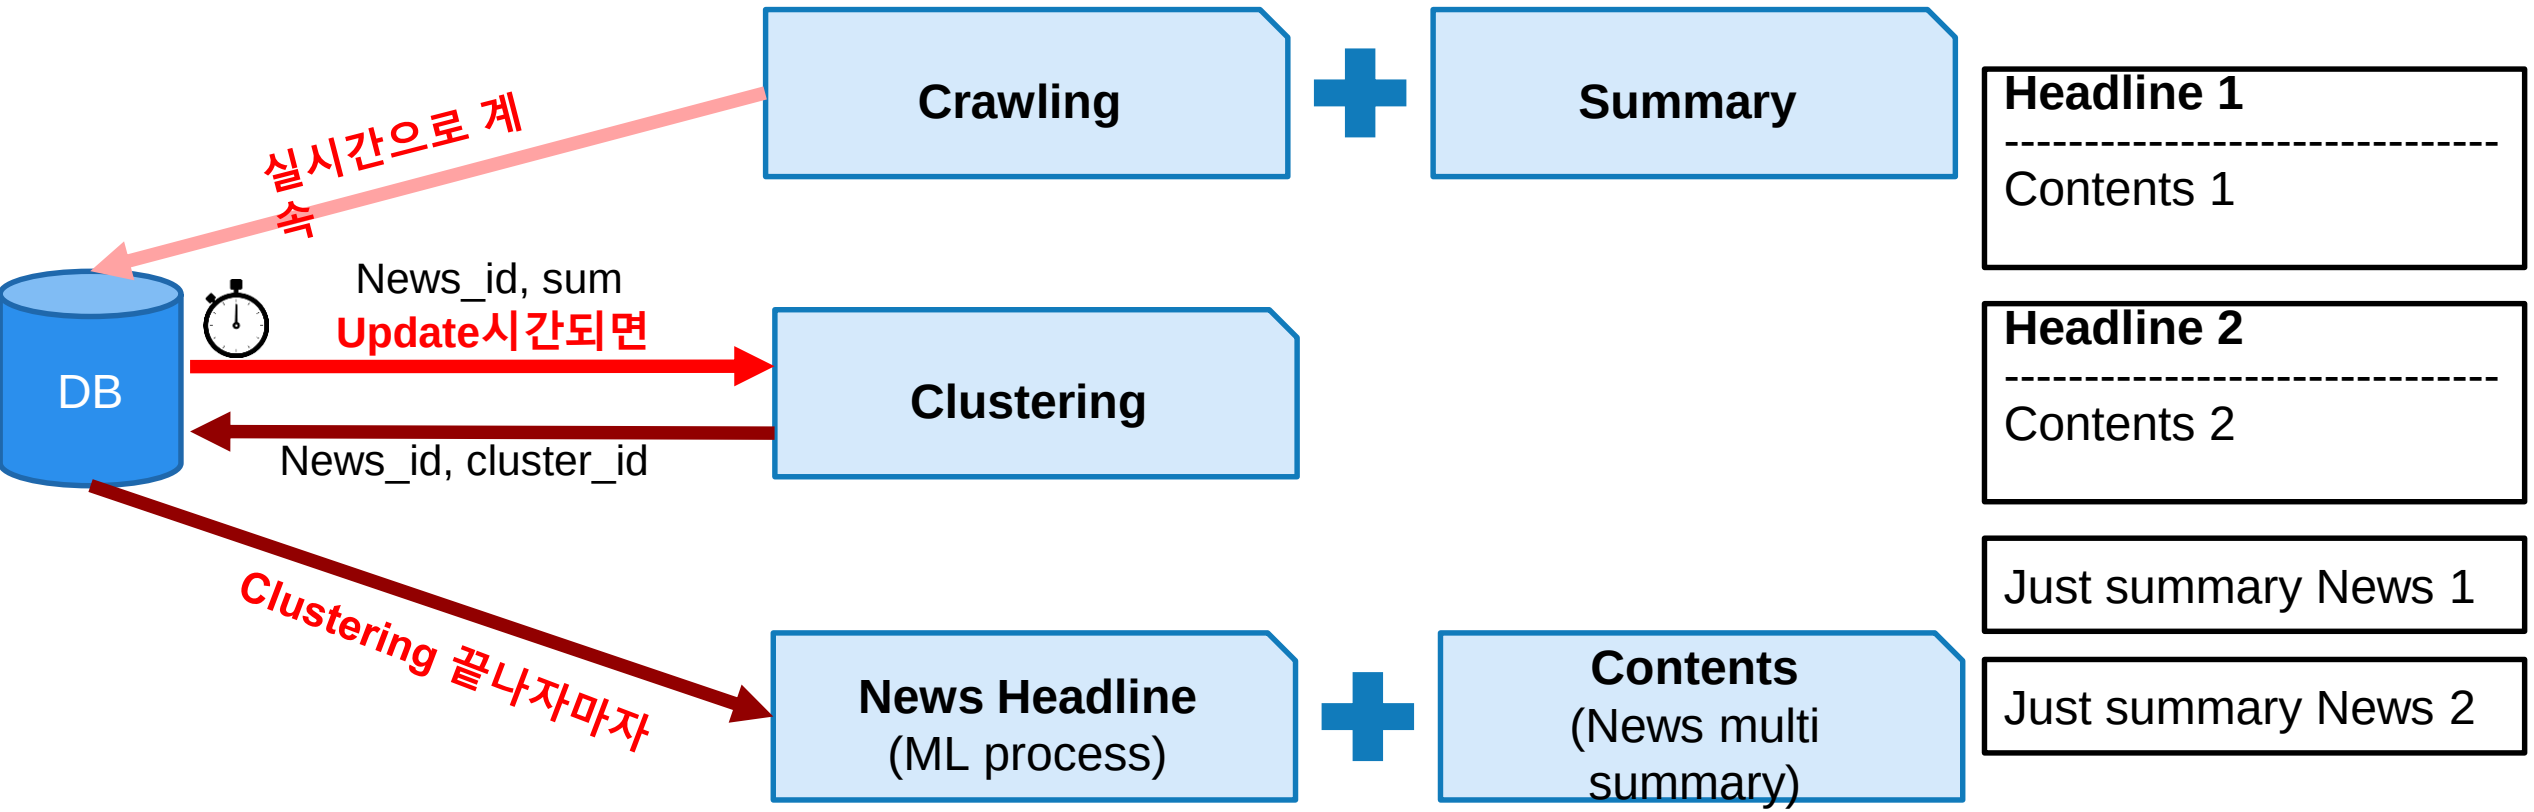

Clustering 도출 결과 : 유사 주제를 가진 뉴스들을 묶는다.

Cluster_id 부여 / 이 외 default

묶음 속에서 중심 주제와 가까운 것은

이때의 Cluster_id는 UUID

Cluster 당 포함 뉴스기사 수 == Cluster 크기

3-3. 뉴스 제공 시스템 구현 현황

- K_means 이용한 Clustering

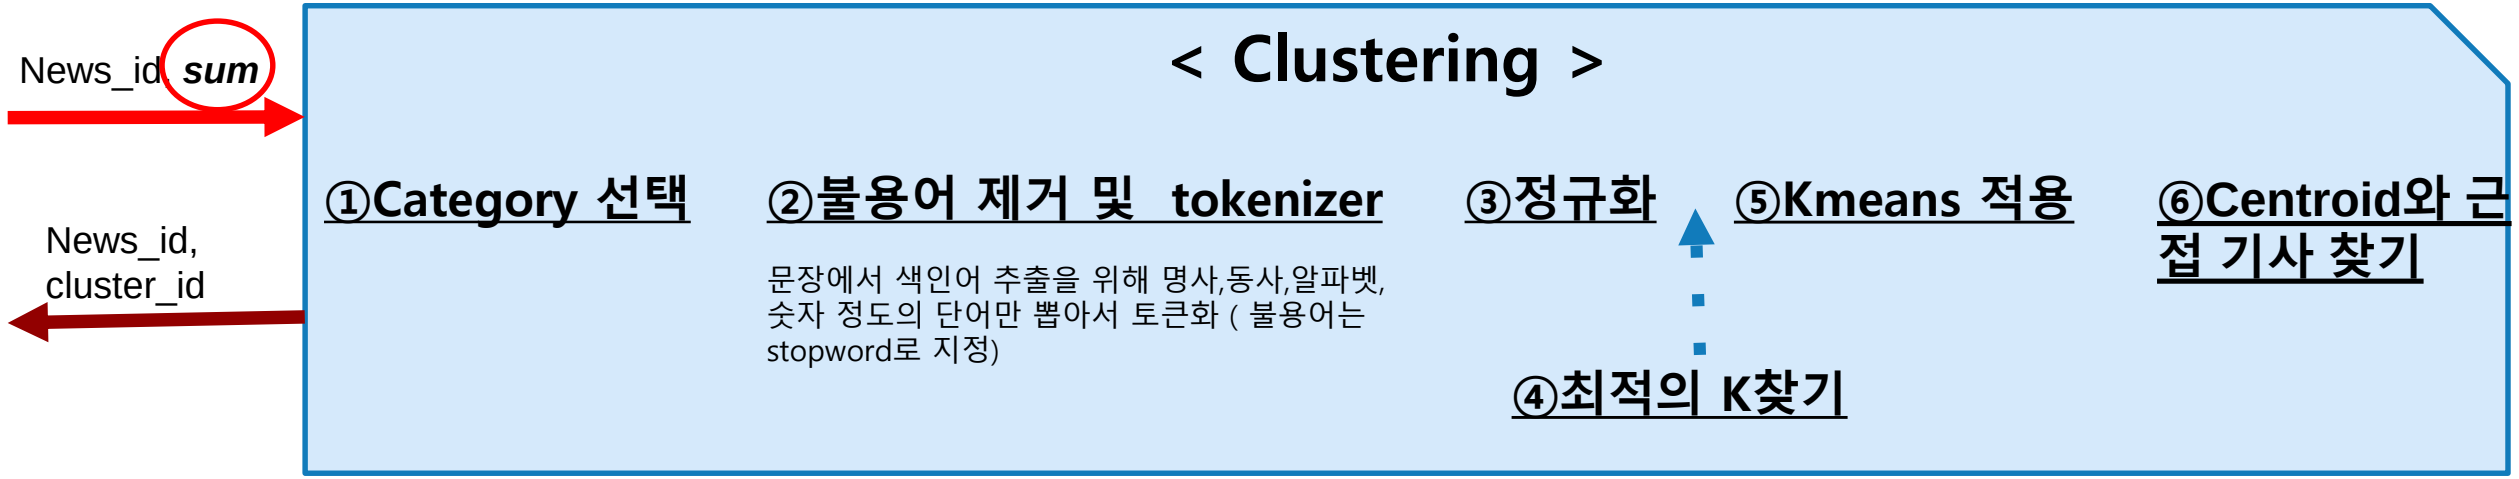

②불용어 제거 및 tokenizer

토큰화 시 참조 API : **Countvectorizer** vs Tfidfvectorizer vs HashingVectorizer

3-3. 뉴스 제공 시스템 구현 현황

- K_means 이용한 Clustering

④최적의 K찾기

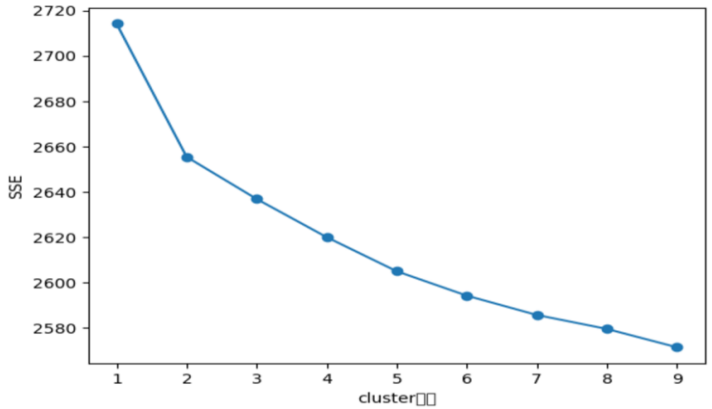

-최적의 K값 찾기 방법 1) elbow 기법

2) 실루엣 기법

-문제점:

두 방법은 K값을 하나하나 다 넣어보고 나온 성능평가 결과를 의미한다.

고로 한 카테고리 당 24시간에 (사회 1만개, 경제 5천개, IT 2천개, 정치 4천개) crawling 시,

- 시간이 오래 걸린다. 1만 dataset을 range 6 내에 Kmeans □ 20분 소요
- 분산이 작을 시
- 문자 데이터에 대한 내용이므로 시각적 판단 기준이 없음 (분산도 그래프 작성의 어려움)
  □ 올바른 clustering 여부

-해결책 : K값에 최대 최소 범위를 지정 (10< K < 20) : 추천, 보여지는 Headline의 편리성과 관련

* 유동 K

: multiprocessing 이용

* 고정 K

3-3. 뉴스 제공 시스템 구현 현황

- K_means 이용한 Clustering

⑥Centroid와 근접 기사 찾기

== MORE 선택 시 보여지는 기사들

(전처리 된 data + 최적의 K) + Kmeans의 각 중심 centroid, Cn과의 vector data의 거리를 측정하여 가까운 순으로 list화

List의 index(0,**N**)까지 근접 기사로 측정
'**N**' == 최대 more 속 기사들
: N이 클수록 낱개 just news가 줄어든다.
N = 20으로 지정
cluster 내 크기가 N보다 작으면 작은 만큼만 도출

근접 기사로 측정된 것만 Cluster_id 부여 / 나머지는 default

3-4. 추천 시스템 구현 진행 현황

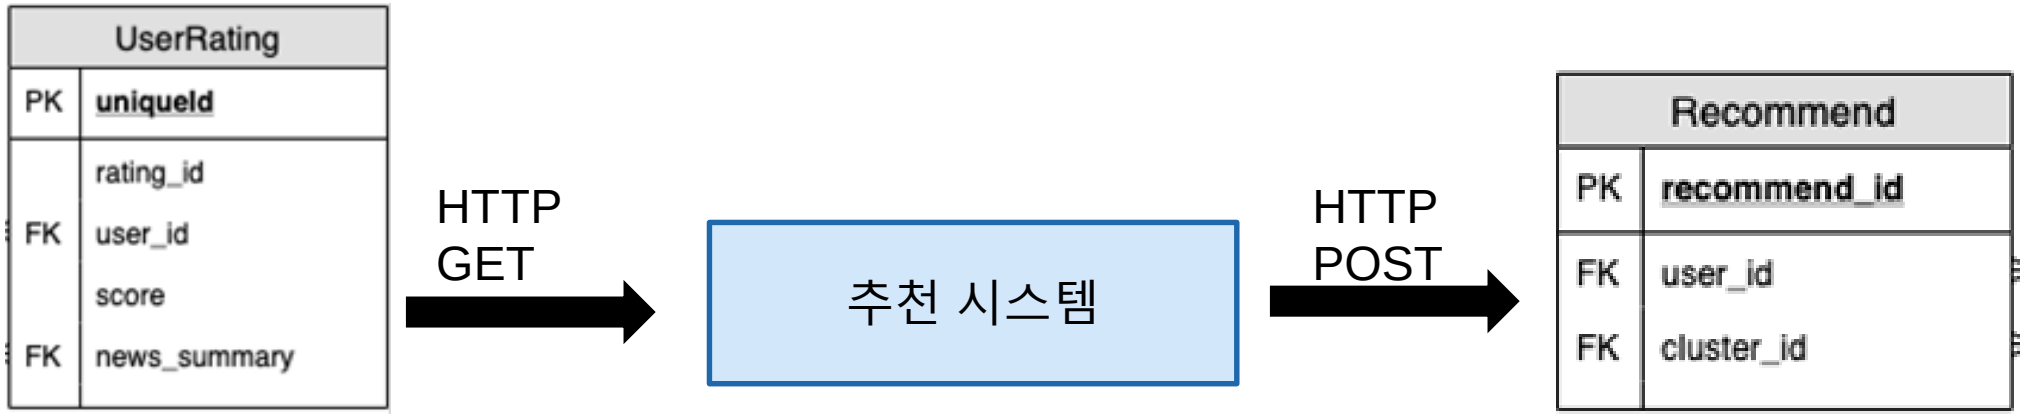

진행현황

UserRating 테이블에서 user_id, score 와 news_summary를 가져와 cluster_id와 user_id를 recommend 테이블로 업데이트 완료

3-4. 추천 시스템 구현 진행 현황

Rating table


```
[
    {
        "rating_id": "055c8196-9b47-4289-8592-a586a7625696",
        "score": 5,
        "user_id": "pFbDe7m55DYtXMgcarlBFgEFhYr1",
        "news_summary": "b47b1456-d816-4f30-8d5c-9d5846a79bb9"
    },
    {
        "rating_id": "4f71ee52-e260-4382-8b30-5e9847765b6b",
        "score": 2,
        "user_id": "R7TdA4s1DiO5QwN7iTJL1ad6e2V2",
        "news_summary": "6fd0f744-5758-45c1-94c5-84a69b893429"
    },
```


Recommend table


```
{
    "recommend_id": "862c007f-d49d-4265-8bce-814f7d2e18df",
    "user_id": "pFbDe7m55DYtXMgcarlBFgEFhYr1",
    "cluster_id": "58d0aa77-1664-4bed-9f45-0e28e8b11171"
},
```


user_id가 pFbDe7m55DYtXMgcarlBFgEFhYr1인 유저에 대한 새로운 뉴스 군집을 Recommend table에 등록 했다.

앞으로의 계획

스케쥴러를 사용하여 주기적으로 추천 시스템 동작

3-5. 헤드라인 제공 기능 구현 진행 현황

① Today server(news provide system)

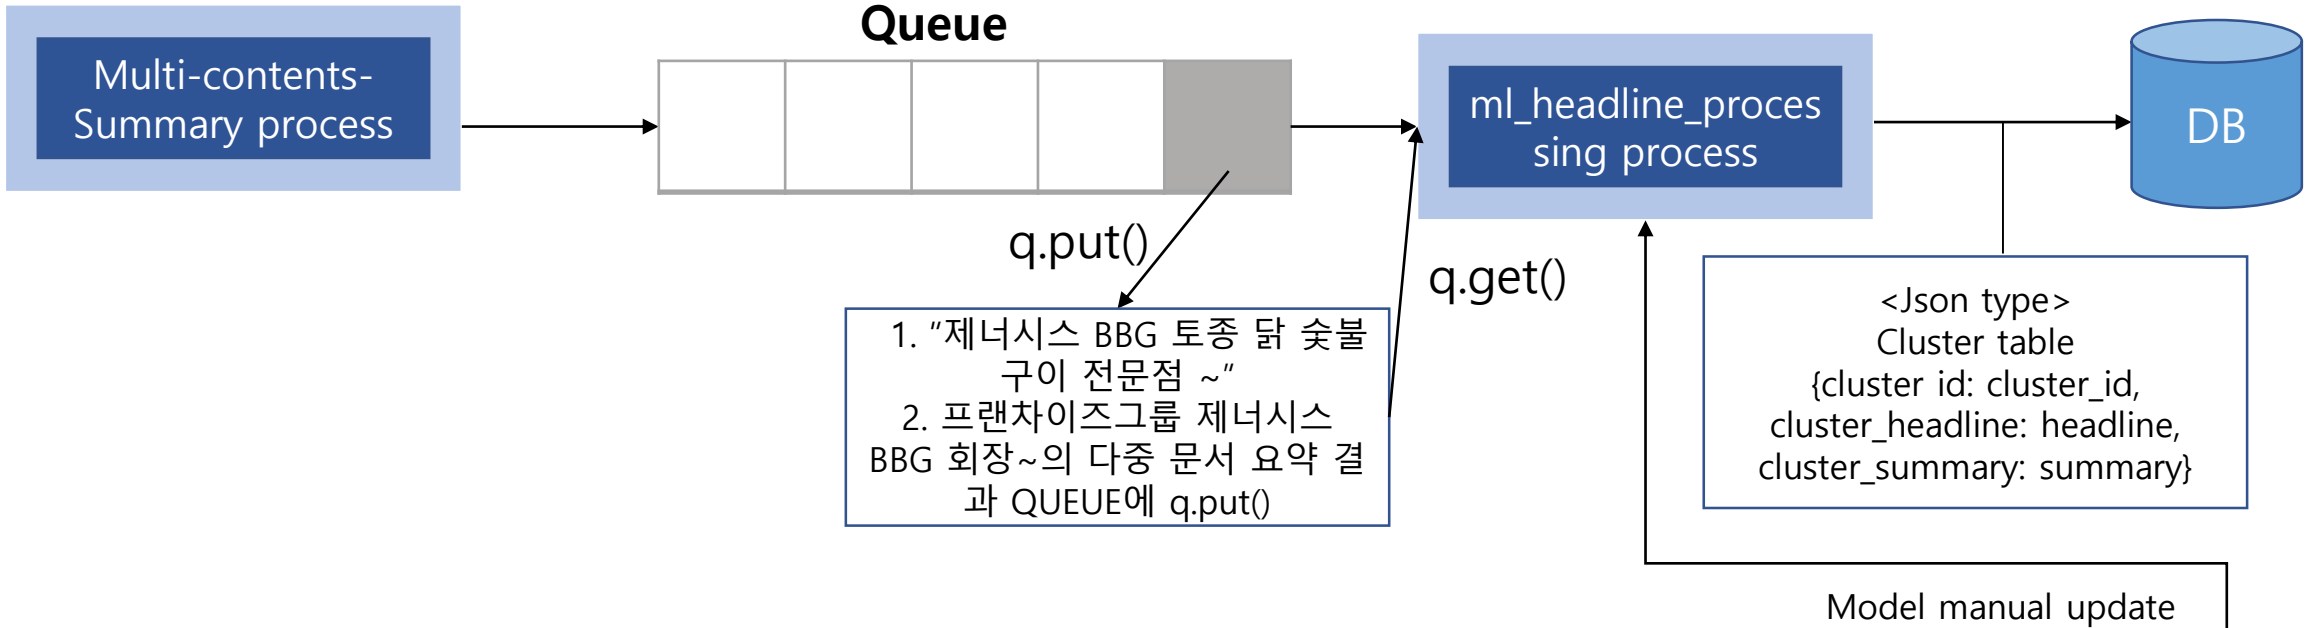

② ml_headline server

3-5. 헤드라인 제공 기능 구현 진행 현황

1. 학습 결과

Step 수	결과(loss,predition, edit result, actual result)
76450	---- step : 76450 time : 14166781839.02959 LOSS : 36.35411338806152 prediction : 최 신 재 재 조 는 는 는 는 < < < < < < < < < < < < < < < < < < < < < < < < < edit result : 최 신 책 물 을 것 오 마 자 비 < < < < < < < < < < < < < < < < < < < < < < < < actual result : 최승호 신동호 책임 물 을 것 오후 마다 자리 비워 ---- Prediction: 최승호 신동호 재귀 재귀 조사장 는 는 는 는
83860	---- step : 83860 time : 14166868565.5033 LOSS : 35.155114364624026 prediction : 롯 연 연 연 연 앞 앞 앞 앞 앞 앞 앞 앞 앞 앞 앞 실 실 실 실 실 실 실 실 실 실 실 실 실 < < edit result : 롯 연 앞 고 와 수 늘 어 < < < < < < < < < < < < < < < < < < < < < < < < < < < actual result : 롯데마트 연말연시 앞두 고 와인 수요 늘 어 ---- Prediction: 롯데마트 연말연시 연말연시 연말연시 연말연시 앞두 앞두 앞두 앞두 앞두 앞두 앞두 앞두 앞두 실 실 실 실 실 실 실< <
94470	---- step : 94470 time : 14166991342.8276 LOSS : 36.3416446685791 prediction : 무 반 반 반 반 반 반 반 반 조 조 조 조 조 < < < < < < < < < < < < < < < < edit result : 애 국 특 침 조 핀 펫 반 기 훔 나 < < < < < < < < < < < < < < < < < < < actual result : 애플 국내 특허 침해 조사 핀 펫 반도체 기술 훔쳤 나 ---- Prediction: 무 반도체 반도체 반도체 반도체 반도체 반도체 조사 조사 조사 조사 조사
100640	---- step : 100640 time : 14167064035.018682 LOSS : 35.92008285522461 prediction : 프 카 카 전 전 전 전 전 전 전 < < < < < < < < < < < < < < < < < < < < < edit result : 프 마 모 에 녹 카 의 캐 < < < < < < < < < < < < < < < < < < < < < < < < actual result : 프렌즈 마블 모노폴리 에 녹인 카카오 의 캐주얼 ---- Prediction:프렌즈 카카오 카카오 전대 전대 전대 전대 전대 전대 전대
113120	---- step : 113120 time : 14167210020.51829 LOSS : 31.90686588287354 prediction : 무 플 무 무 무 애 애 애 시 시 시 시 시 시 시 시 < < < < < < < < < < < < < < edit result : 무 위 애 아 의 카 이 반 특 침 여 조 < < < < < < < < < < < < < < < < < < actual result : 무역 위 애플 아이폰 의 카 이스트 반도체 특허 침해 여부 조사 ---- Prediction: 무역 플 무역 무역 무역 애 애 시험 시험 시험 시험 시험 시험 시험
116250	---- step : 116430 time : 14167249093.43153 LOSS : 24.451529884338385 prediction : 지 뮤 엔 음 음 음 및 및 및 및 < < < < < < < < < < < < < < < < < < < < edit result : 지 뮤 엔 와 신 음 및 음 유 계 체 < < < < < < < < < < < < < < < < < < < actual result : 지니 뮤직 엔터 와 신규 음원 및 음반 유통 계약 체결 ---- Prediction:지니 뮤직 엔터 음원 음원 음원 및 및 및 및

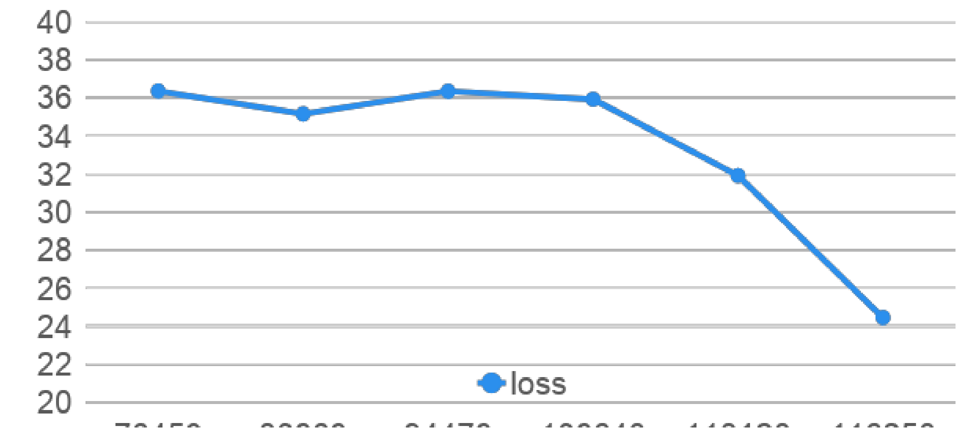

4. 작품 시연 동영상

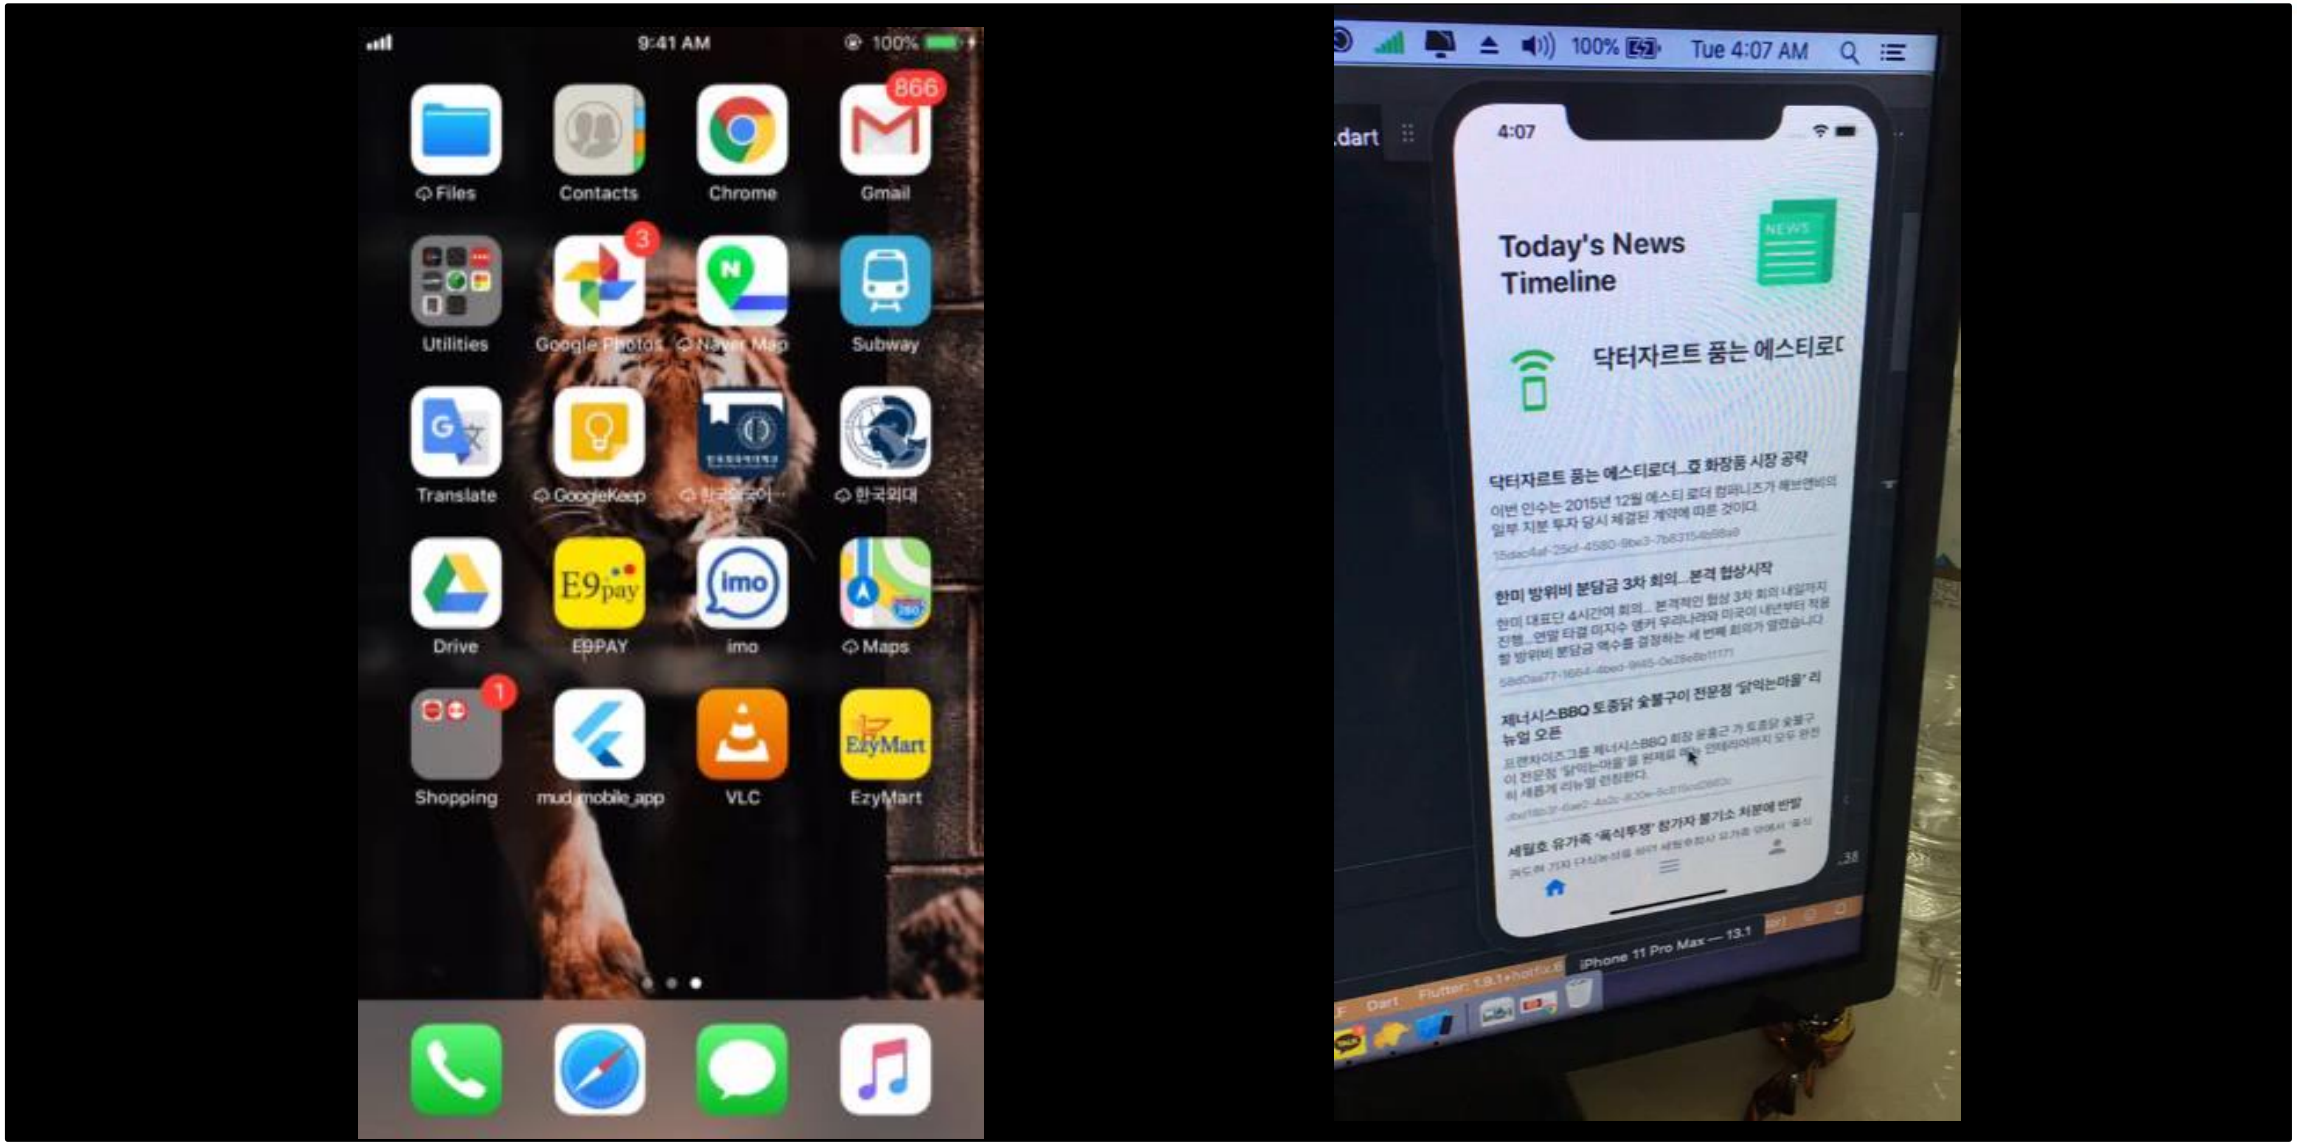
9:41 AM
100%
Files
Contacts
Chrome
Gmail
866
Utilities
Google Photos
Naver Map
Subway
Translate
GoogleKeep
한국외대
Drive
E9PAY
imo
Maps
Shopping
mud_mobile_app
VLC
EzyMart
100%
Tue 4:07 AM
4:07
Today's News
Timeline
닥터자르트 품는 에스티로더
iPhone 11 Pro Max — 13.1

5. 향후 계획 및 담당

주차 별 계획

프로젝트 기간	2019.9.9~2019.12.9												
개발 내용	프로젝트 기간												
	1주	2주	3주	4주	5주	6주	7주	8주	9주	10주	11주	12주	13주
아이디어 회의 및 계획				●									
프로젝트 관련 자료 조사					●								
역할 분담 및 핵심 기술 조사							●						
사업 제안서 작성						●							
요구사항 및 상세 설계 작성							●			●			
서버 및 데이터 베이스 구현								●					
앱 구현									●				
뉴스 크롤링								●					
클러스터링 시스템구현										●	●		
요약 시스템 구성(추상적)										●	●		
요약 시스템 구성(추출적)										●			
추천 시스템 구현										●			
개별 테스트 및 보안											●		
통합 테스트 및 보안												●	
최종 발표 및 시연													●

● 완료

● 미완료

● 예정

5. 향후 계획 및 담당

향후 계획

개발 내용	11주	12주	13주	담당자
클러스터링 시스템 구현				김혜원
헤드라인 추상적 요약 구현				박주영
스크랩 기능 구현				이산가 비두샤
다중요약				홍승환, 김아연
뉴스 제공 시스템 병렬처리				홍승환, 김아연
개별 테스트 및 보안				전 팀원
통합 테스트 및 보안				전 팀원
최종 문서 수정				전 팀원
최종 발표 및 시연				전 팀원

Thank You

감사합니다.